

# !Shazam

## 1. Abstract:

!Shazam este un instrument digital, portabil și extrem de rapid, folosit pentru recunoașterea melodiilor, pentru ca utilizatorii să poată descoperi noi *jam*-uri cu precizie și ușurință. Pentru a oferi aceste caracteristici am decis să folosim puterea de procesare înaltă pe care FPGA-urile o permit datorită arhitecturii capabile să efectueze multe operații în paralel. Astfel, ne propunem să înregistrăm sunetele folosind placa audio a plăcii. După achiziția completă a datelor vom folosi o transformată Fourier rapidă care să aplice o convoluție (de tip periodic) pentru a găsi frecvențele undelor sinusoidale care ar putea alcătui semnalul. Dacă au fost folosite  $N$  intrări (sample-uri), se pot detecta maxim  $N/2$  frecvențe distincte care alcătuiesc semnalul (din cauza procesului de [aliasing](#)). Deoarece urechea umană poate percepe unde sinusoidale cu frecvențe între 20Hz și 20kHz, vom folosi un model care poate determina un maxim de  $2^{14} = 16384$  frecvențe distincte în intervalul  $[0, 16384]$ , ceea ce înseamnă că vom avea nevoie de  $2^{15} = 32768$  intrări pentru a avea o reprezentare care poate distinge sunetele suficient de similar cu urechea umană. Dacă presupunem o perioadă  $\Delta T_{\text{achiziționare}}$  în care placa așteaptă toate intrările și o perioadă  $\Delta T_{\text{procesare}}$  în care placa realizează calculele pentru determinarea frecvențelor (timp în care placa nu mai poate stoca alte input-uri) atunci numim  $\Delta T_{\text{SW}} = \Delta T_{\text{achiziționare}} + \Delta T_{\text{procesare}}$  durata de timp a unui „sliding-window”. Putem atunci considera orice melodie ca alcătuită din  $P$  perioade  $P = \frac{T_{\text{melodie}}}{\Delta T_{\text{SW}}}$ . Pentru fiecare din aceste perioade se va alege semnalul sinusoidal cu cea mai mare energie stocată ( $E = \frac{1}{2} \rho \cdot A \cdot f^2 \cdot \lambda$  - care depinde cel mai mult de frecvența  $f$  și amplitudinea  $A$ ). Astfel putem realiza un algoritm care ține cont de unda cu cea mai mare energie în  $\Delta T_{\text{SW}}$  și momentul de timp  $T$  în care a fost înregistrată. Această pereche energie-timp va fi stocată în baza de date. Un cântec va avea  $P$  perechi energie-timp stocate la ID-ul acestuia. Pentru algoritmul de *recunoaștere* vom compara cele  $X$  pachete venite cu cele  $P$  pachete stocate și vom realiza o histogramă cu numărul perioadelor relative care verifică o relație de adiacență când două *hash*-uri prezintă un *match*.

## 2. Implementare:

Vom folosi placa DE10-LITE deoarece reprezintă o variantă minimală care acoperă toate cerințele proiectului (intrare analog, chip ADC, unitate de procesare și pini pentru comunicarea cu o placă Arduino).

### 2.1. Achiziția datelor:

Pentru achiziția datelor vom lega un microfon la intrarea A0 a connector-ului Arduino, care va mapa în interior Canalul 0 al plăcii de sunet:

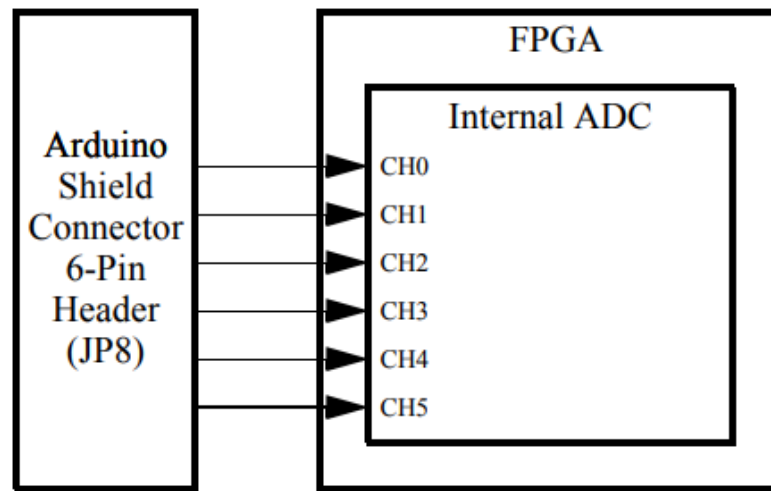


Figure 3. Signals to and from the ADC on the **DE10-Lite**

(Pentru un scurt tutorial care prezintă modul în care putem citi valorile analog de la CH-uri consultați pagina 59 din manualul plăcii: [DE10-LITE Manual](#))

După specificația prezentată mai sus, cât și în [Using the DE-Series ADC Controller \(intel.com\)](#), vom primi sample-uri de 12 biți odată la 16 clock cycle-uri. Utilizând un calcul simplu, presupunând frecvența plăcii de 10 MHz  $\Rightarrow \Delta T_{ACHIZ MIN} = 0.054s$  pentru 32.768 sample-uri.

## 2.2 Procesarea datelor

Pentru procesarea datelor vom utiliza specificațiile din articolul [\(PDF\) The Fast Fourier Transform in Hardware: A Tutorial Based on an FPGA Implementation \(researchgate.net\)](#) care presupune un *data-width* de 12 biți. Unitatea centrală de procesare a FFT-ului va fi modulul Butterfly care primește 32.768 de intrări și produce 32.768 ieșiri. Datorită algoritmului de generare al perechilor de *input-uri*:

Iteration level $i \downarrow$	Butterfly address pairs $j \rightarrow$
Level 0:	$\{0, 1\} \{2, 3\} \{4, 5\} \{6, 7\} \{8, 9\} \dots$
Level 1:	$\{0, 2\} \{1, 3\} \{4, 6\} \{5, 7\} \{8, 10\} \dots$
Level 2:	$\{0, 4\} \{1, 5\} \{2, 6\} \{3, 7\} \{8, 12\} \dots$
Level 3:	$\{0, 8\} \{1, 9\} \{2, 10\} \{3, 11\} \{4, 12\} \dots$
$\vdots$	

putem instanția la fiecare nivel 32.768 de module care primesc ca input pentru cei doi operanzi:

```

module two_operand_butterfly_eval (
  input [11: 0] A,
  input [11: 0] B,
  input [11: 0] twiddle

  output [11: 0] out1,
  output [11: 0] out2,
);

  // pseudocode:
  assign out1 = A + B * twiddle;
  assign out2 = A - B * twiddle;
endmodule

```

unde:

```

// memory location for input A in decimal form
integer m;

wire [11: 0] A = prev_butterfly_output[m: m + 11];

// memory location for input B in decimal form
integer n;
wire [11: 0] B = prev_butterfly_output[n: n + 11];

```

iar rezultatul fiecărui modul va fi stocat într-o memorie RAM (aici numită *prev\_butterfly\_output*). Algoritmul este:

$$m = \text{Rotate}_5(2j, i)$$

$$n = \text{Rotate}_5(2j + 1, i)$$

where  $\text{Rotate}_N(x, y)$  indicates a circular left shift of  $N$  bit word  $x$  by  $y$  bits.

După cum se specifică și în articol, vom folosi operații cu virgulă fixă deoarece input-ul este de lungime fixă (12 biți).

*Twiddle*-urile vor fi urcate în memoria ROM a plăcii. Pentru a extrage adresa *twiddle*-ul de la nivelul  $i$  pentru perechea  $j$ , putem folosi:

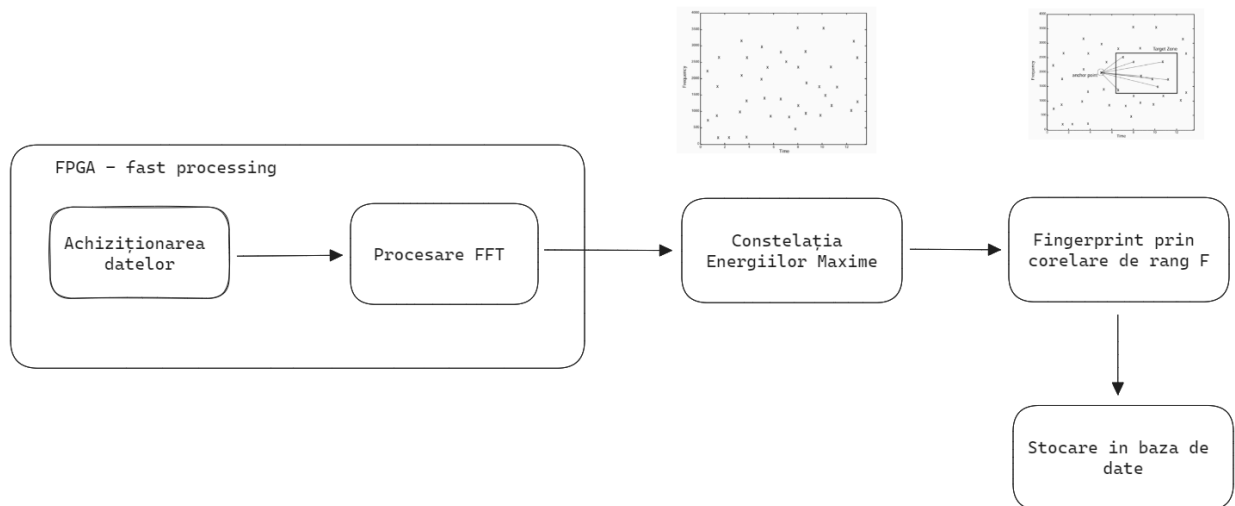
The twiddle factor addresses are found by masking out the  $N - 1 - i$  least significant bits of  $j$ .

După ce toate ultimul nivel a fost computat, încărcăm datele pe Arduino, unde va avea loc algoritmul de *fingerprint*.




### 2.3. Diagrama de decizie:

Placa va avea trei stări principale: „Waiting”, „Training” și „Recognizing”:

Dacă este selectat modul „Training”:



Dacă este selectat modul „Recognizing”:



Constelația  
Energiilor Maxime

Fingerprint prin  
corelare de rang F

Căutare folosind  
histograme de  
corelări multiple

